

UNIVERSIDAD DE GUAYAQUIL

Facultad de Ciencias Matemáticas y Física

Descubrimiento de Patrones de Comorbilidad Síntoma-Enfermedad mediante

Minería de Datos

Autor:

Choez Paredes Yerlyn Alexi

Asignatura:

Almacenes de Datos y Minería de Datos

Docente:

Ing. Oscar Dario Leon Granizo

Fecha:

Julio, 2026

Indicé

Resumen.....	5
Introducción	6
1. Comprensión del negocio	7
1.1 Descripción del problema	7
1.2 Preguntas del análisis.....	8
1.3 Objetivo general.....	8
1.4 Objetivos específicos	8
1.5 Pertinencia de las reglas de asociación	9
1.6 Alcance del concepto de comorbilidad	9
2. Herramientas y fuentes de datos	9
2.1 Entorno de trabajo.....	9
2.2 Librerías	10
2.3 Dataset obligatorio.....	11
2.4 Dataset complementario NHANES	11
3. Carga de datos y dificultades resueltas	12
3.1 Intento de descarga automática	12
3.2 Corrección de la ruta.....	13

3.3 Problemas de orden de ejecución.....	13
4. Comprensión y preparación del dataset principal	13
4.1 Exploración inicial	13
4.2 Limpieza y normalización.....	16
4.3 Formato transaccional binario.....	18
5. Minería de datos con Apriori	18
5.1 Primera configuración.....	19
5.2 Segunda configuración.....	19
5.3 Filtrado y selección de reglas.....	21
6. Clasificación con Naive Bayes	22
6.1 Preparación y entrenamiento.....	22
6.2 Resultados.....	23
6.3 Comparación con Apriori.....	25
7. Análisis complementario de comorbilidad con NHANES.....	25
7.1 Preparación y unión	26
7.2 Frecuencia de enfermedades	28
7.3 Apriori en NHANES	29
8. Evaluación e integración de patrones	32
9. Conocimiento accionable: tarjetas de alerta	33
9.1 Hipotiroidismo	34

9.2 Malaria	34
9.3 Enfermedad de úlcera péptica	34
9.4 GERD.....	34
9.5 Asma bronquial	35
10. Limitaciones.....	36
11. Conclusiones	37
12. Referencia	39



Resumen

El presente proyecto aplicó el proceso de Descubrimiento de Conocimiento en Bases de Datos, conocido como KDD, para estudiar relaciones entre síntomas y enfermedades que puedan servir como apoyo en el triaje inicial de un centro de atención primaria. El propósito no fue construir un sistema de diagnóstico ni reemplazar el criterio médico, sino reconocer patrones históricos, presentarlos de forma comprensible y señalar sus limitaciones. Como fuente obligatoria se utilizó el conjunto *Disease Symptom Prediction*, disponible en Kaggle. Este recurso contiene enfermedades, síntomas, descripciones, precauciones y pesos de gravedad. Para ampliar el alcance hacia la comorbilidad real entre enfermedades se añadió, de manera independiente, la encuesta *NHANES 2013-2014*.

El archivo principal contenía 4.920 registros, 41 enfermedades y hasta 17 síntomas por fila. Durante la limpieza se encontraron 4.616 registros duplicados, por lo que el análisis definitivo se realizó con 304 perfiles únicos. Apriori se ejecutó con dos configuraciones. La primera produjo 365 conjuntos frecuentes y 549 reglas; la segunda produjo 19.645 conjuntos y 136.722 reglas. Después de aplicar criterios de soporte, confianza, lift, número de síntomas y diversidad, se seleccionaron 15 reglas correspondientes a 15 enfermedades diferentes. Como contraste se entrenó Bernoulli Naive Bayes con una división estratificada de 80 % para entrenamiento y 20 % para prueba. El modelo alcanzó 96,72 % de exactitud sobre perfiles sin duplicados.

NHANES permitió estudiar enfermedades que fueron reportadas por una misma persona, identificada de manera anónima mediante SEQN. Se conservaron 9.768 participantes con respuestas válidas; 2.075 de ellos presentaron dos o más enfermedades seleccionadas. Apriori encontró patrones enfermedad-enfermedad y se eligieron 15 parejas no reflejadas. Entre las asociaciones más destacadas estuvieron enfisema con EPOC, angina con enfermedad coronaria y ataque cardíaco con enfermedad coronaria. Finalmente, se elaboraron cinco tarjetas de alerta con síntomas, soporte, confianza, lift y precauciones. Los hallazgos son asociaciones estadísticas del conjunto analizado y deben utilizarse únicamente como apoyo académico y orientativo.

Introducción

En la atención primaria, el primer contacto con una persona suele empezar con una explicación sencilla de lo que siente. Dolor, fiebre, mareo, picazón o dificultad para respirar pueden aparecer solos, pero con frecuencia se presentan como combinaciones. Para el personal responsable del triaje, reconocer esos conjuntos puede aportar una orientación inicial al momento de organizar la atención. Aun así, una coincidencia estadística no constituye un diagnóstico, pues la historia clínica, el examen físico y el criterio profesional continúan siendo indispensables.

La minería de datos ofrece métodos para revisar numerosos registros y descubrir relaciones que no siempre son evidentes a simple vista. Las reglas de asociación expresan los resultados de manera cercana: cuando aparece una combinación de síntomas, también puede aparecer determinada enfermedad. Por otra parte, la clasificación aprende a partir de ejemplos conocidos y estima la categoría de un registro nuevo. El empleo conjunto de ambos enfoques permite contrastar una explicación basada en reglas con el desempeño predictivo de un modelo.

El trabajo siguió las etapas de KDD: selección, comprensión, limpieza, transformación, minería, evaluación e interpretación del conocimiento. Se desarrolló en Google Colab con Python. El estudio principal respondió a la relación síntoma-enfermedad, mientras que NHANES permitió incorporar una dimensión adicional de enfermedad-enfermedad sin inventar pacientes ni unir diagnósticos de personas diferentes. Esta separación metodológica fue importante para conservar la validez de los datos.

1. Comprensión del negocio

1.1 Descripción del problema

El caso corresponde a un centro de salud que desea fortalecer el triaje inicial. En esta etapa se reciben los síntomas informados por el paciente y se establece una prioridad de atención. La dificultad radica en que muchos síntomas son comunes a varias enfermedades. Por ejemplo, un dolor aislado puede tener numerosas explicaciones, mientras que una combinación particular puede ofrecer una referencia más concreta. El sistema propuesto busca organizar conocimiento histórico que ayude a reconocer estas combinaciones.

La solución planteada no pretende emitir diagnósticos automáticos. Las reglas y predicciones deben verse como señales de apoyo que podrían orientar una revisión más detenida. Además, las precauciones incluidas en las tarjetas proceden del dataset y no sustituyen recomendaciones personalizadas. Esta aclaración es necesaria porque los resultados numéricos pueden parecer muy seguros, especialmente cuando una regla presenta confianza de 100 %, aunque su soporte sea reducido.

1.2 Preguntas del análisis

El estudio buscó responder las siguientes preguntas: ¿cuáles son los síntomas más frecuentes?, ¿qué enfermedades aparecen en más perfiles únicos?, ¿qué combinaciones de dos o más síntomas se relacionan con una enfermedad?, ¿qué reglas superan los criterios mínimos de soporte, confianza y lift?, ¿qué tan bien clasifica Naive Bayes los perfiles no vistos durante el entrenamiento?, ¿en qué enfermedades se producen errores?, ¿qué diagnósticos aparecen juntos en participantes reales de NHANES?, y ¿cómo pueden comunicarse los hallazgos a personal no técnico?

1.3 Objetivo general

Aplicar el proceso KDD sobre datasets reales de síntomas y enfermedades para extraer reglas de asociación y patrones de clasificación que apoyen la toma de decisiones clínicas iniciales, manteniendo una interpretación prudente y comprensible.

1.4 Objetivos específicos

1. Seleccionar, limpiar y transformar el dataset obligatorio a un formato transaccional de presencia o ausencia.
2. Aplicar Apriori con dos configuraciones de soporte y confianza para descubrir combinaciones de síntomas asociadas con enfermedades.
3. Entrenar Bernoulli Naive Bayes para predecir la enfermedad a partir de síntomas y contrastar sus resultados con Apriori.
4. Filtrar reglas triviales o repetitivas mediante soporte, confianza, lift, cantidad de antecedentes y diversidad de enfermedades.

5. Incorporar NHANES como análisis independiente para estudiar enfermedades simultáneas en una misma persona real.
6. Elaborar cinco tarjetas de alerta con información comprensible y precauciones procedentes del dataset obligatorio.

1.5 Pertinencia de las reglas de asociación

Apriori resulta pertinente porque cada registro puede entenderse como una transacción compuesta por elementos que aparecen juntos. En el análisis principal, esos elementos son síntomas y una enfermedad. En NHANES, los elementos son las enfermedades reportadas por un participante. El soporte indica la proporción de registros que contiene una asociación completa; la confianza señala la proporción de casos con el antecedente que también presenta el consecuente; y el lift compara esa relación con la frecuencia habitual del consecuente. Un lift superior a uno indica que la combinación ocurre más de lo esperado dentro de la muestra.

1.6 Alcance del concepto de comorbilidad

El dataset obligatorio contiene una sola enfermedad por registro. Por ello permite analizar coocurrencia de síntomas y asociación síntoma-enfermedad, pero no demuestra que dos enfermedades estén presentes en una misma persona. Para atender esta limitación se utilizó NHANES, donde SEQN identifica a cada participante y permite reunir sus respuestas sin crear casos artificiales. Así, el proyecto conserva el análisis obligatorio y añade un estudio legítimo de comorbilidad enfermedad-enfermedad.

2. Herramientas y fuentes de datos

2.1 Entorno de trabajo

Se eligió Google Colab porque permite ejecutar Python desde el navegador y mantener el notebook en Google Drive. Esta opción fue sencilla para cargar archivos, ejecutar el proceso por etapas y visualizar los resultados. También ayudó a reproducir el análisis, siempre que las celdas se ejecuten desde el inicio y se vuelvan a cargar los archivos cuando la sesión temporal se reinicia.

2.2 Librerías

Se utilizaron "os" y "zipfile" para administrar rutas y descomprimir archivos; "warnings" para controlar avisos del entorno; "pandas" y "numpy" para limpieza, transformación y cálculos; y "matplotlib" y "seaborn" para gráficos. "mlxtend" proporcionó TransactionEncoder, apriori y association_rules. "scikit-learn" aportó train_test_split, BernoulliNB, accuracy_score, classification_report y confusion_matrix. Estas librerías se encuentran dentro de las herramientas permitidas para el proyecto.

```
"""
1. Manejo de archivos y datos
"""
import os
import zipfile
import warnings
import numpy as np
import pandas as pd

"""
2. Visualización
"""
import matplotlib.pyplot as plt
import seaborn as sns

"""
3. Carga de archivos en Google Colab
"""
from google.colab import files

"""
4. Reglas de asociación
"""
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori, association_rules

"""
5. Clasificación y evaluación
"""
from sklearn.model_selection import train_test_split
from sklearn.metrics import (accuracy_score, classification_report, confusion_matrix)
from sklearn.naive_bayes import BernoulliNB
from sklearn.metrics import accuracy_score

"""
6. Configuración
"""
warnings.filterwarnings("ignore")
pd.set_option("display.max_columns", None)
sns.set_theme(style="whitegrid")
```

Justificación:

Se seleccionaron pandas y NumPy para organizar y transformar los datos; Matplotlib y Seaborn para elaborar las visualizaciones; Mlxtend para aplicar Apriori; y Scikit-learn para entrenar y evaluar el clasificador Naive Bayes.

2.3 Dataset obligatorio

El conjunto Disease Symptom Prediction incluyó cuatro archivos: "dataset.csv", con enfermedades y síntomas; "symptom_Description.csv", con descripciones; "symptom_precaution.csv", con hasta cuatro precauciones por enfermedad; y "Symptom-severity.csv", con pesos asociados a los síntomas. El archivo central tuvo 4.920 filas y 18 columnas: una enfermedad y 17 posibles síntomas.

2.4 Dataset complementario NHANES

La encuesta *National Health and Nutrition Examination Survey 2013-2014* fue obtenida de Kaggle, en la publicación del CDC. Se utilizaron "demographic.csv" y "questionnaire.csv", ambos con 10.175 filas. El primero contenía 47 columnas y el segundo 953. La unión se realizó mediante "SEQN", identificador anónimo que no presentó duplicados en ninguno de los dos archivos. NHANES no se mezcló con el dataset principal, porque sus estructuras, poblaciones y objetivos son diferentes.

Descripción y uso de las fuentes de datos

<i>Fuente</i>	<i>Unidad analizada</i>	<i>Uso</i>
Disease Symptom Prediction	Perfil de síntomas asociado con una enfermedad	Aplicación de Apriori, Naive Bayes y elaboración de tarjetas informativas
NHANES 2013-2014	Participante identificado mediante "SEQN"	Análisis de comorbilidad entre enfermedades

3. Carga de datos y dificultades resueltas

3.1 Intento de descarga automática

Al comenzar se instaló "opendatasets" y se intentó descargar el archivo directamente desde Kaggle. El procedimiento solicitó credenciales y no funcionó de manera estable en la sesión de Colab. Para no depender de esta autenticación, se descargó el archivo ZIP desde Kaggle y se cargó manualmente con "files.upload()". Luego se descomprimió con "zipfile". Esta alternativa fue más fácil de repetir y permitió verificar de forma visible el archivo seleccionado.

```
uploaded = files.upload()
```

```
df = pd.read_csv(ruta + "/dataset.csv")
descripcion = pd.read_csv(ruta + "/symptom_Description.csv")
precauciones = pd.read_csv(ruta + "/symptom_precaution.csv")
gravedad = pd.read_csv(ruta + "/Symptom-severity.csv")
```

Justificación: Se utilizó la carga local porque el procedimiento inicial mediante opendatasets y las credenciales de Kaggle presentó dificultades de acceso y rutas. La carga manual del archivo comprimido permitió controlar su ubicación y verificar directamente la lectura de los cuatro archivos obligatorios.

3.2 Corrección de la ruta

Después de la carga apareció un “FileNotFoundError”, porque se buscó “dataset.csv” directamente dentro de “Disease_Symptom_Prediction”. Una revisión de carpetas mostró que los cuatro CSV estaban en “Disease_Symptom_Prediction/archive”. Se corrigió la variable de ruta y la lectura se completó. Esta experiencia dejó una enseñanza práctica: antes de modificar el código de análisis conviene comprobar la estructura real del archivo comprimido.

3.3 Problemas de orden de ejecución

En otro momento se presentó “NameError” para “tabla_reglas_finales”. La tabla era requerida por las tarjetas, pero su celda todavía no se había ejecutado o había sido duplicada con otro nombre. El notebook se reorganizó para crear una sola tabla final antes de las tarjetas y usar el mismo nombre en todas las secciones. También se diferenciaron variables como “accuracy_principal” para evitar confundir resultados de modelos distintos.

4. Comprensión y preparación del dataset principal

4.1 Exploración inicial

El dataset principal presentó 4.920 registros y 41 enfermedades. Las cuatro primeras columnas de síntomas no tuvieron ausencias relevantes: “Symptom_1”, “Symptom_2” y “Symptom_3” estuvieron completas, mientras que “Symptom_4” tuvo 348 valores faltantes. A partir de allí, la ausencia aumentó: “Symptom_5” tuvo 1.206 y “Symptom_17” llegó a 4.848. Este patrón era esperado, porque no todas las enfermedades poseen 17 síntomas registrados. Los vacíos representan que no hay otro síntoma en esa posición, por lo cual no se rellenaron con datos inventados.


Valores faltantes por columna del dataset principal

```
df.isnull().sum()
```

	0
Disease	0
Symptom_1	0
Symptom_2	0
Symptom_3	0
Symptom_4	348
Symptom_5	1206
Symptom_6	1986
Symptom_7	2652
Symptom_8	2976
Symptom_9	3228
Symptom_10	3408
Symptom_11	3726
Symptom_12	4176
Symptom_13	4416
Symptom_14	4614
Symptom_15	4680
Symptom_16	4728
Symptom_17	4848

dtype: int64


Justificación: Las ausencias aumentan en las últimas columnas porque cada perfil contiene una cantidad diferente de síntomas. Se conservaron como ausencia real y no como un error que debiera imputarse.



Interpretación: Se cuantificaron los valores faltantes para determinar si correspondían a errores o a diferencias naturales en la cantidad de síntomas por registro. No fueron sustituidos por síntomas inventados; posteriormente se excluyeron al construir las listas transaccionales.

La representación inicial de enfermedades estaba influida por filas repetidas. Por este motivo, la gráfica definitiva se calculó sobre perfiles únicos. Mostrar las 15 enfermedades con más registros facilita la lectura y evita una figura demasiado cargada. Su finalidad no es afirmar prevalencia clínica, sino describir cómo está formada esta base académica.


Quince enfermedades con mayor cantidad de perfiles únicos



Interpretación: La figura describe la representación interna del dataset después de eliminar duplicados. Estas frecuencias pertenecen a la base y no deben interpretarse como prevalencia de la población.

La frecuencia de síntomas se obtuvo al reunir las columnas en una lista, retirar los valores ausentes y contar cada término. Los veinte síntomas más frecuentes ayudan a comprender cuáles tienen mayor presencia. Sin embargo, un síntoma frecuente no necesariamente discrimina bien una enfermedad, porque puede formar parte de varios diagnósticos. Por ello, Apriori se concentró en combinaciones de dos o más síntomas.

Veinte síntomas más frecuentes en los perfiles únicos



Interpretación: Los síntomas frecuentes ofrecen una visión general del contenido, pero su valor práctico depende de la combinación en que aparecen y de las métricas de la regla resultante.

4.2 Limpieza y normalización

Se creó una copia para conservar los datos originales. Los síntomas se transformaron a minúsculas, se eliminaron espacios externos y se sustituyeron espacios internos por guiones bajos. Luego se construyó “lista_sintomas”, que reúne únicamente los síntomas presentes por fila. Esta representación fue la base tanto para las transacciones de Apriori como para la matriz binaria de clasificación.

La revisión detectó 4.616 registros duplicados de un total de 4.920. En consecuencia, quedaron 304 perfiles únicos. Esta reducción parece grande, pero era necesaria: dividir aleatoriamente las filas repetidas podía colocar el mismo perfil en entrenamiento y prueba. De hecho, el primer modelo alcanzó 100 % de exactitud, resultado que parecía excelente, aunque estaba favorecido por esa repetición. Al retirar duplicados antes de dividir, la exactitud definitiva descendió a 96,72 %, una estimación más honesta.

Registros antes y después de eliminar duplicados

```
"""Registros antes de eliminar los Duplicados"""  
print("Registros originales:", len(df_limpio))  
  
Registros originales: 4920  
  
"""Registros despues de eliminar duplicados"""  
print("Registros sin duplicados:", len(df_limpio_sin_dup))  
  
Registros sin duplicados: 304  
  
"""Cantidad de registros duplicados eliminados"""  
print("Duplicados eliminados:", len(df_limpio) - len(df_limpio_sin_dup))  
  
Duplicados eliminados: 4616
```

Interpretación: La diferencia confirma que la base repetía numerosos perfiles.

Eliminar duplicados redujo el riesgo de evaluar el modelo con casos que ya había visto durante el entrenamiento.

Justificación: Se eliminaron 4.616 registros repetidos y se conservaron 304 perfiles únicos. Esta decisión evitó que la repetición artificial de perfiles aumentara la frecuencia de determinados síntomas, alterara el soporte de Apriori y produjera una evaluación excesivamente optimista del clasificador.

4.3 Formato transaccional binario

Para Apriori, cada perfil se convirtió en una transacción que contiene sus síntomas y un elemento con prefijo "disease_". "TransactionEncoder" generó columnas booleanas: "True" cuando el elemento está presente y "False" cuando está ausente. Para Naive Bayes se creó una matriz separada de 304 filas y 132 columnas: 131 variables predictoras de síntomas y la columna objetivo "Disease". Esta separación evitó que el nombre de la enfermedad ingresara accidentalmente como predictor.

```
columnas_sintomas = [col for col in df.columns if col != "Disease"]
df_limpio["lista_sintomas"] = df_limpio[columnas_sintomas].apply(
    lambda fila: [sintoma for sintoma in fila.dropna().tolist()],
    axis=1)
df_limpio[["Disease", "lista_sintomas"]].head()
```

Justificación técnica: Los síntomas de cada registro se agruparon en una lista, descartando únicamente los valores nulos. Esta estructura permitió representar cada perfil como una transacción y prepararlo para su posterior codificación binaria.

5. Minería de datos con A priori

```
df_apriori = df_limpio_sin_dup.copy()
df_apriori["Disease_item"] = ("disease_" + df_apriori["Disease"].str.lower().str.strip().str.replace(" ", "_"))
df_apriori["transaccion"] = df_apriori["lista_sintomas"] + df_apriori["Disease_item"].apply(lambda x: [x])
df_apriori[["Disease", "transaccion"]].head()
```

```
te_apriori = TransactionEncoder()  
transacciones_codificadas = te_apriori.fit(df_apriori["transaccion"]).transform(df_apriori["transaccion"])  
df_transacciones = pd.DataFrame(transacciones_codificadas, columns=te_apriori.columns_)
```

Justificación: Apriori necesita una matriz de presencia y ausencia. Por ello, cada síntoma y enfermedad se convirtió en una variable booleana mediante TransactionEncoder: True indica presencia y False ausencia dentro del perfil analizado.

5.1 Primera configuración

La primera ejecución utilizó soporte mínimo de 0,05, confianza mínima de 0,60 y longitud máxima de tres elementos. Fue una configuración conservadora, pensada para recuperar patrones con mayor presencia y mantener un volumen manejable. Produjo 365 conjuntos frecuentes y 549 reglas. Su principal ventaja fue la claridad, aunque podía dejar fuera asociaciones útiles de enfermedades poco representadas.

```
"""Esta configuracion busca reglas mas generales"""  
itemsets_1 = apriori(df_transacciones, min_support=0.05, use_colnames=True, max_len=3, low_memory=True)  
reglas_1 = association_rules(itemsets_1, metric="confidence", min_threshold=0.60)  
reglas_1.sort_values(by="lift", ascending=False).head(10)
```

Justificación: Se eligió min_support=0.05 y confidence=0.60 para obtener reglas más generales, con suficiente frecuencia y confiabilidad, evitando patrones demasiado específicos o poco representativos del conjunto de datos.

5.2 Segunda configuración

La segunda ejecución utilizó soporte mínimo de 0,01, confianza mínima de 0,50 y longitud máxima de cuatro elementos. Al ser más flexible, produjo 19.645 conjuntos frecuentes y 136.722 reglas. Durante una prueba anterior, esta configuración agotó la memoria de Colab. El problema se resolvió con “max_len=4” y “low_memory=True”, límites que conservaron combinaciones pertinentes sin intentar expandir conjuntos demasiado largos.

```
itemsets_2 = apriori(df_transacciones, min_support=0.01, use_colnames=True, max_len=4, low_memory=True)
reglas_2 = association_rules(itemsets_2, metric="confidence", min_threshold=0.50)
reglas_2.sort_values(by="lift", ascending=False).head(10)
```

Justificación: Se redujo el soporte (0.01) y la confianza (0.50) para descubrir reglas menos frecuentes, pero potencialmente relevantes, permitiendo identificar asociaciones más específicas entre síntomas y enfermedades.


```
comparacion_apriori = pd.DataFrame({
    "Configuración": ["Primera", "Segunda"],
    "Soporte mínimo": [0.05, 0.01],
    "Confianza mínima": [0.60, 0.50],
    "Itemsets encontrados": [len(itemsets_1), len(itemsets_2)],
    "Reglas encontradas": [len(reglas_1), len(reglas_2)]
})

comparacion_apriori
```

	Configuración	Soporte mínimo	Confianza mínima	Itemsets encontrados	Reglas encontradas
0	Primera	0.05	0.6	365	549
1	Segunda	0.01	0.5	19645	136722

Justificación: La primera configuración utilizó criterios más conservadores para obtener patrones con mayor presencia. La segunda redujo el soporte y la confianza mínimos para descubrir asociaciones menos frecuentes. Debido al aumento considerable de reglas, fue necesario aplicar filtros posteriores de calidad e interpretación.

Comparación de las dos configuraciones Apriori del dataset principal



Interpretación: La configuración flexible amplió notablemente la búsqueda. Este aumento justificó aplicar filtros posteriores de calidad, diversidad y utilidad práctica.

5.3 Filtrado y selección de reglas

Primero se conservaron reglas cuyo consecuente fuera una sola enfermedad y cuyo antecedente contuviera al menos dos síntomas. Después se exigió lift mayor que uno, confianza de al menos 0,60 y soporte de al menos 0,01. Una selección inicial de las primeras 15 reglas repetía las mismas enfermedades varias veces. Para corregirlo, se ordenaron las candidatas y se tomó una regla por enfermedad. El resultado final reunió 15 reglas de 15 enfermedades distintas.

Reglas síntoma-enfermedad seleccionadas

Reglas seleccionadas: 15
Enfermedades diferentes: 15

	antecedents	consequents	support	confidence	lift
3235	(dizziness, back_pain)	(disease_cervical_spondylosis)	0.013158	1.0	50.666667
3741	(high_fever, blister)	(disease_impetigo)	0.013158	1.0	50.666667
4211	(bloody_stool, constipation)	(disease_dimorphic_hemorrhoids(piles))	0.013158	1.0	50.666667
5463	(burning_micturition, itching)	(disease_drug_reaction)	0.013158	1.0	50.666667
5805	(dizziness, chest_pain)	(disease_hypertension)	0.013158	1.0	50.666667
10205	(movement_stiffness, muscle_weakness)	(disease_arthritis)	0.013158	1.0	50.666667
1629	(indigestion, abdominal_pain)	(disease_peptic_ulcer_disease)	0.016447	1.0	43.428571
2482	(chest_pain, acidity)	(disease_gerd)	0.016447	1.0	43.428571
4781	(breathlessness, family_history)	(disease_bronchial_asthma)	0.016447	1.0	43.428571
10065	(spinning_movements, headache)	(disease_vertigo)_paroxysmal_positional_vertigo)	0.016447	1.0	43.428571
11608	(loss_of_appetite, family_history)	(disease_hepatitis_c)	0.016447	1.0	43.428571
12585	(joint_pain, hip_joint_pain)	(disease_osteoarthritis)	0.016447	1.0	43.428571
12781	(inflammatory_nails, joint_pain)	(disease_pсориаsis)	0.016447	1.0	43.428571
2013	(abnormal_menstruation, brittle_nails)	(disease_hypothyroidism)	0.026316	1.0	38.000000
12494	(sweating, muscle_pain)	(disease_malaria)	0.023026	1.0	38.000000

La confianza de 100 % significa que, dentro de estos 304 perfiles, cada vez que apareció la combinación también apareció la enfermedad indicada. No significa certeza clínica. Los soportes se encuentran entre 1,32 % y 2,63 %, de modo que las combinaciones son poco frecuentes. El lift alto también está influido por la baja frecuencia de algunas enfermedades. Por eso las reglas se interpretaron como señales explicables y no como pruebas diagnósticas.


6. Clasificación con Naive Bayes

6.1 Preparación y entrenamiento

Bernoulli Naive Bayes fue elegido porque trabaja bien con variables binarias. Las 304 filas se dividieron de manera estratificada: 243 para entrenamiento y 61 para prueba. La estratificación procuró conservar la distribución de enfermedades en ambos grupos. Se utilizó “random_state=42” para que la partición pudiera reproducirse.

6.2 Resultados


El modelo obtuvo 96,72 % de exactitud. La mayoría de las enfermedades del pequeño conjunto de prueba fue clasificada correctamente, aunque varias clases tuvieron apenas uno o dos ejemplos. Se observaron dificultades concretas: “Heart attack” no fue acertada en su único caso; “Chronic colestasis” tuvo recall de 0,50; y GERD y Hepatitis D compartieron algunas confusiones. Por ello, la exactitud global debe acompañarse con el reporte por enfermedad y la matriz de confusión.



Interpretación: La diagonal concentra la mayoría de los aciertos. Los valores fuera de ella muestran enfermedades confundidas y recuerdan que una exactitud alta no implica un rendimiento perfecto en cada clase.

La matriz completa de 41 enfermedades es útil como evidencia técnica, pero resulta difícil de leer en una presentación. Por eso se añadió una gráfica con las diez enfermedades de menor tasa de acierto. Esta visualización dirige la atención hacia los puntos que requieren más datos o una validación más amplia.

Enfermedades con menor tasa de acierto



Interpretación: Naive Bayes alcanzó 96,72 % general, aunque presentó errores en algunas enfermedades. El resultado no debe interpretarse como un diagnóstico infalible.

```
accuracy_principal = accuracy_score(y_test, y_pred)

print(f"Exactitud del dataset principal: {accuracy_principal * 100:.2f}%")

Exactitud del dataset principal: 96.72%
```


Justificación: Se utilizaron varias métricas porque la exactitud general no describe por sí sola el comportamiento de cada enfermedad. El modelo alcanzó 96,72 %, pero presentó dificultades en algunas clases, como ataque cardíaco y ciertos casos de colestasis crónica. Por tanto, no debe interpretarse como un sistema de diagnóstico.

6.3 Comparación con Apriori

Naive Bayes y Apriori responden preguntas diferentes. El clasificador elige una enfermedad para un perfil completo y se evalúa con datos de prueba. Apriori, en cambio, explica qué elementos aparecen juntos y mide la fuerza de cada asociación. La coincidencia entre ambos enfoques aporta respaldo descriptivo, pero no vuelve clínica una relación. Apriori es más sencillo de comunicar; Naive Bayes resume mejor la capacidad predictiva. Juntos ofrecen una visión complementaria.

7. Análisis complementario de comorbilidad con NHANES

```
variables_enfermedades = {
    "MCQ010": "Asma",
    "MCQ070": "Psoriasis",
    "MCQ160A": "Artritis",
    "MCQ160B": "Insuficiencia cardiaca",
    "MCQ160C": "Enfermedad coronaria",
    "MCQ160D": "Angina",
    "MCQ160E": "Ataque cardiaco",
    "MCQ160F": "Accidente cerebrovascular",
    "MCQ160G": "Enfisema",
    "MCQ160K": "Bronquitis cronica",
    "MCQ160L": "Enfermedad hepatica",
    "MCQ160M": "Problema tiroideo",
    "MCQ160N": "Gota",
    "MCQ160O": "EPOC",
    "DIQ010": "Diabetes",
    "BPQ020": "Hipertension"
}
```

```
variables_disponibles = {
    codigo: enfermedad for codigo, enfermedad in variables_enfermedades.items()
    if codigo in df_nhanes.columns
}

variables_no_encontradas = {
    codigo for codigo in variables_enfermedades
    if codigo not in df_nhanes.columns
}

print("Cantidad de variables encontradas:", len(variables_disponibles))
print("\nVariables disponibles:")
display(variables_disponibles)
print("\nVariables no encontradas:")
print(variables_no_encontradas)

Cantidad de variables encontradas: 16

Variables disponibles:
{'MCQ010': 'Asma',
 'MCQ070': 'Psoriasis',
 'MCQ160A': 'Artritis',
 'MCQ160B': 'Insuficiencia cardiaca',
 'MCQ160C': 'Enfermedad coronaria',
 'MCQ160D': 'Angina',
 'MCQ160E': 'Ataque cardiaco',
 'MCQ160F': 'Accidente cerebrovascular',
 'MCQ160G': 'Enfisema',
 'MCQ160K': 'Bronquitis cronica',
 'MCQ160L': 'Enfermedad hepatica',
 'MCQ160M': 'Problema tiroideo',
 'MCQ160N': 'Gota',
 'MCQ160O': 'EPOC',
 'DIQ010': 'Diabetes',
 'BPQ020': 'Hipertension'}

Variables no encontradas:
[]
```

```

codigos_enfermedades = list(variables_disponibles.keys())
columnas_comorbilidad = ["SEQN"] + codigos_enfermedades

df_base_comorbilidad = df_nhanes[columnas_comorbilidad].copy()

print("Dimensiones antes del filtro:", df_base_comorbilidad.shape)

Dimensiones antes del filtro: (10175, 17)

"""Identifica las respuestas validas"""
respuesta_valida = df_base_comorbilidad[codigos_enfermedades].isin([1, 2]).any(axis=1)

df_base_comorbilidad = (
    df_base_comorbilidad[respuesta_valida]
    .reset_index(drop=True)
    .copy()
)

print("Participantes con respuestas validas:", len(df_base_comorbilidad))

Participantes con respuestas validas: 9768

```


Justificación: Se conservaron 9.768 participantes con al menos una respuesta válida en las 16 condiciones seleccionadas. De ellos, 2.075 reportaron dos o más enfermedades, por lo que fueron identificados descriptivamente como participantes con comorbilidad.

7.1 Preparación y unión

Los archivos de demografía y cuestionario tenían 10.175 participantes cada uno. Se verificó que 'SEQN' no estuviera duplicado y se realizó una unión interna, obteniendo 10.175 coincidencias y 999 columnas. Se localizaron 16 variables de enfermedades: asma, psoriasis, artritis, insuficiencia cardiaca, enfermedad coronaria, angina, ataque cardiaco, accidente cerebrovascular, enfisema, bronquitis crónica, enfermedad hepática, problema tiroideo, gota, EPOC, diabetes e hipertensión.

Las respuestas de NHANES fueron recodificadas con cuidado. Se consideraron válidos los códigos 1 y 2, correspondientes a sí y no según las variables seleccionadas; otros códigos, como no sabe o sin respuesta, no se convirtieron en diagnósticos. Se conservaron 9.768 participantes con al menos una respuesta válida. De ellos, 5.494 no reportaron ninguna de las 16 enfermedades, 2.199 reportaron una y 2.075 reportaron dos o más. La suma comprobada fue 9.768.


Distribución de participantes según enfermedades



Interpretación: El 54,94 % no reportó una condición seleccionada, el 21,99 % reportó una y el 20,75 % presentó dos o más. Este último grupo describe la comorbilidad observada.

Se conservaron en Apriori todos los participantes con respuestas válidas, incluso quienes no tenían diagnósticos positivos. Esta decisión mantuvo como denominador a 9.768 personas y evitó inflar artificialmente el soporte calculándolo solo entre quienes ya tenían comorbilidad. El grupo de 2.075 se utilizó para describir la cantidad de personas con dos o más condiciones, no como único universo de minería.

Cantidad exacta de enfermedades por participante




Interpretación: La figura muestra la concentración de participantes en cero, una y varias condiciones. Los casos con más diagnósticos son menos numerosos, pero permiten descubrir asociaciones múltiples.

7.2 Frecuencia de enfermedades


La hipertensión fue la condición más frecuente, con 2.174 participantes (22,26 %), seguida por asma con 1.538 (15,75 %) y artritis con 1.508 (15,44 %). Diabetes apareció en 737 participantes (7,55 %) y los problemas tiroideos en 601 (6,15 %). La condición menos frecuente entre las seleccionadas fue enfisema, con 95 casos (0,97 %). Estas diferencias explican por qué el soporte debe analizarse junto con confianza y lift.

Frecuencia de las 16 enfermedades seleccionadas en NHANES



Interpretación: Hipertensión, asma y artritis dominan la muestra. Una enfermedad frecuente puede formar parte de muchas reglas, por lo que no basta con observar su cantidad absoluta.


7.3 Apriori en NHANES



Justificación: La configuración conservadora priorizó asociaciones presentes en al menos el 1 % de los participantes. La flexible permitió examinar patrones menos frecuentes y combinaciones de hasta tres enfermedades. Sus 148 reglas fueron sometidas posteriormente a filtros adicionales.

La configuración conservadora utilizó soporte mínimo de 0,01, confianza de 0,40 y longitud máxima de dos. Produjo 44 conjuntos frecuentes y 26 reglas. La configuración flexible redujo el soporte a 0,005, la confianza a 0,30 y permitió hasta tres elementos. Produjo 108 conjuntos y 148 reglas. La segunda configuración se utilizó para la selección final, acompañada por filtros adicionales.

Comparación de configuraciones Apriori en NHANES



Interpretación: La configuración flexible recuperó asociaciones menos frecuentes y más complejas. La selección final mantuvo únicamente reglas con lift superior a uno y métricas mínimas justificadas.


Se conservaron reglas simples con una enfermedad antecedente y una consecuente. Como Apriori puede generar $A \rightarrow B$ y $B \rightarrow A$, se construyó una pareja ordenada y se dejó una sola dirección, priorizando la de mayor confianza. De 48 reglas simples quedaron 42 parejas únicas y se seleccionaron las 15 primeras después de aplicar soporte de al menos 0,005, confianza de al menos 0,30 y lift mayor que uno.

Patrones finales de comorbilidad en NHANES

***	Enfermedad antecedente	Enfermedad asociada	support	confidence	lift	Participantes con ambas enfermedades
40	Enfisema	Epoc	0.006962	0.715789	36.415789	68
5	Angina	Enfermedad Coronaria	0.007678	0.551471	23.218813	75
26	Ataque Cardíaco	Enfermedad Coronaria	0.011364	0.482609	20.319490	111
4	Angina	Ataque Cardíaco	0.005733	0.411765	17.487468	56
28	Insuficiencia Cardíaca	Ataque Cardíaco	0.007371	0.395604	16.801147	72
38	Insuficiencia Cardíaca	Enfermedad Coronaria	0.007166	0.384615	16.193634	70
30	Epoc	Bronquitis Crónica	0.007883	0.401042	12.241797	77
35	Insuficiencia Cardíaca	Diabetes	0.007473	0.401099	5.316057	73
24	Ataque Cardíaco	Diabetes	0.008804	0.373913	4.955743	86
1	Accidente Cerebrovascular	Diabetes	0.007576	0.366337	4.855327	74
32	Enfermedad Coronaria	Diabetes	0.008497	0.357759	4.741637	83
14	Epoc	Artritis	0.012899	0.656250	4.250829	126
33	Gota	Diabetes	0.007371	0.307692	4.078071	72
13	Enfisema	Artritis	0.006040	0.621053	4.022840	59
18	Insuficiencia Cardíaca	Artritis	0.011159	0.598901	3.879354	109

La asociación enfisema con EPOC tuvo el lift más alto, 36,42, y una confianza de 71,58 %, aunque solo estuvo presente en 68 participantes. La relación ataque cardíaco con enfermedad coronaria tuvo 111 participantes y lift de 20,32. También aparecieron relaciones cardiovasculares con diabetes. Estos resultados son coherentes como patrones descriptivos, pero el análisis no demuestra que una enfermedad cause otra.

Lift de los principales patrones de comorbilidad



Interpretación: Todas las reglas superan lift igual a uno y representan asociaciones mayores a las esperadas en la muestra. El soporte y el número de participantes deben acompañar siempre al lift.

Las reglas múltiples, como enfisema + artritis → EPOC, se conservaron en una tabla adicional. Se encontraron 79 reglas con dos o más enfermedades antecedentes. Se presentan como análisis complementario y no se mezclan con la tabla principal de parejas, porque su lectura y su soporte responden a combinaciones de mayor complejidad.

8. Evaluación e integración de patrones

El análisis principal y NHANES no se mezclaron. El primero estudió perfiles de síntomas y una enfermedad, aplicó Apriori, entrenó Naive Bayes y alimentó las tarjetas. NHANES estudió participantes reales y sus enfermedades simultáneas. Esta separación evitó crear pacientes sintéticos y permitió responder dos preguntas relacionadas, pero distintas.

Integración de los dos análisis del proyecto

Integración de los análisis del proyecto

DATASET PRINCIPAL

Síntomas → Enfermedad

Apriori + Naive Bayes
Exactitud: 96,72%

NHANES

Enfermedad → Enfermedad

Apriori
Soporte, confianza y lift

Interpretación: El dataset obligatorio explica síntomas y clasificación; NHANES amplía el estudio hacia enfermedades simultáneas sin alterar ni mezclar las poblaciones.

No se calculó exactitud para NHANES porque allí no se entrenó un clasificador. Apriori no predice una etiqueta de prueba y, por tanto, no se evalúa con “accuracy”. Sus resultados se valoraron mediante soporte, confianza, lift, cantidad de participantes, eliminación de reglas reflejadas y revisión práctica de las asociaciones.

9. Conocimiento accionable: tarjetas de alerta

Las tarjetas se construyeron con reglas del dataset obligatorio y precauciones de “symptom_precaution.csv”. Se eligieron cinco enfermedades distintas y se priorizaron reglas con mayor soporte dentro de la selección final. El nivel de confiabilidad consideró conjuntamente confianza y soporte. Aunque las cinco reglas tuvieron confianza de 100 %, se clasificaron como confiabilidad media debido a su bajo soporte. Esta decisión corrigió una primera versión que mostraba todas las tarjetas como confiabilidad alta.

9.1 Hipotiroidismo

La tarjeta asocia menstruación anormal y uñas quebradizas con hipotiroidismo. El soporte fue 2,63 %, la confianza 100 % y el lift 38,00. Las precauciones del dataset son reducir el estrés, hacer ejercicio, alimentarse de manera saludable y dormir adecuadamente. La confianza describe los perfiles analizados, mientras el soporte reducido exige prudencia.

9.2 Malaria

La regla relaciona dolor muscular y sudoración con malaria. Presentó soporte de 2,30 %, confianza de 100 % y lift de 38,00. Las precauciones son acudir al hospital más cercano, evitar alimentos grasos y no vegetarianos, y mantener alejados los mosquitos. La recomendación de acudir a un servicio de salud debe destacarse por encima de cualquier interpretación automática.

9.3 Enfermedad de úlcera péptica

La tarjeta presenta dolor abdominal e indigestión, con soporte de 1,64 %, confianza de 100 % y lift de 43,43. Las precauciones del dataset incluyen evitar alimentos grasos o picantes, consumir alimentos probióticos, eliminar la leche y limitar el alcohol. Estas indicaciones proceden de la fuente y no equivalen a una receta personalizada.

9.4 GERD

La regla asocia acidez y dolor de pecho con enfermedad por reflujo gastroesofágico. Su soporte fue 1,64 %, la confianza 100 % y el lift 43,43. Las precauciones son evitar alimentos grasos o picantes, no acostarse después de comer, mantener un peso saludable y realizar ejercicio. El dolor de pecho también puede requerir valoración urgente según el contexto clínico.

9.5 Asma bronquial

La tarjeta relaciona falta de aire y antecedentes familiares con asma bronquial. Presentó soporte de 1,64 %, confianza de 100 % y lift de 43,43. Las precauciones incluidas son usar ropa holgada, respirar profundamente, alejarse del desencadenante y buscar ayuda. Ante una dificultad respiratoria importante, la valoración profesional no debe retrasarse.

Tarjetas de alerta para cinco enfermedades





Justificación: Las cinco enfermedades fueron seleccionadas considerando soporte, confianza, lift y diversidad. Sus nombres se normalizaron para relacionarlos con el archivo de precauciones. Las tarjetas presentan los patrones de manera comprensible, pero no sustituyen la evaluación de un profesional de la salud.

10. Limitaciones

El dataset principal es académico y presenta numerosos perfiles repetidos. Después de eliminarlos quedaron 304 casos para 41 enfermedades, por lo que varias clases tuvieron uno o dos ejemplos en la prueba. La exactitud de 96,72 % debe entenderse dentro de ese tamaño reducido. Sería necesario validar el modelo con registros clínicos independientes, más variados y recogidos bajo protocolos claros antes de considerar cualquier uso real.

Las reglas con confianza de 100 % tienen soporte bajo. Esto significa que fueron consistentes en la muestra, pero aparecieron pocas veces. Además, el lift puede elevarse cuando la enfermedad consecuente es poco frecuente. Ninguna de estas métricas demuestra causalidad, gravedad, urgencia ni certeza diagnóstica.

En NHANES, las condiciones seleccionadas corresponden principalmente a respuestas sobre diagnósticos previamente comunicados por profesionales y pueden estar sujetas a memoria o autorreporte. Algunas preguntas se aplican a grupos de edad específicos. No se incorporaron los pesos complejos de encuesta, por lo que los porcentajes describen los participantes analizados y no deben presentarse como estimaciones nacionales de Estados Unidos.

Las precauciones de las tarjetas proceden del dataset de Kaggle y fueron conservadas para cumplir la consigna. No fueron verificadas como guías clínicas actuales ni adaptadas a edad, embarazo, alergias, medicamentos u otras condiciones. Por ese motivo, se presentan como información de la fuente y no como consejo médico.

11. Conclusiones

El proyecto cumplió el proceso KDD sobre datos reales y transformó una estructura de síntomas distribuidos en columnas a transacciones binarias. La limpieza reveló que 4.616 de los 4.920 registros principales estaban duplicados. Trabajar con 304 perfiles únicos evitó que esos duplicados produjeran una evaluación artificialmente perfecta y permitió obtener una exactitud final de 96,72 % con Bernoulli Naive Bayes.

Apriori cumplió su función explicativa. Las dos configuraciones mostraron el equilibrio entre buscar patrones frecuentes y ampliar la exploración hacia asociaciones menos comunes. El filtrado final reunió 15 reglas de 15 enfermedades, en lugar de repetir varias reglas de unas pocas condiciones. Aunque todas alcanzaron confianza de 100 %, sus soportes reducidos obligaron a mantener una interpretación prudente.

NHANES amplió correctamente el alcance del trabajo. La identificación mediante `SEQN` permitió analizar enfermedades reportadas por una misma persona y encontrar asociaciones enfermedad-enfermedad sin inventar pacientes. De 9.768 participantes con respuestas válidas, 2.075 presentaron dos o más condiciones seleccionadas. Las reglas más fuertes se concentraron en relaciones respiratorias y cardiovasculares, además de asociaciones con diabetes y artritis.

La combinación de Apriori y Naive Bayes resultó útil porque un método explica asociaciones y el otro evalúa clasificación. Las tarjetas tradujeron parte de los resultados a un formato accesible, pero su propósito continúa siendo orientativo. En conjunto, el proyecto demuestra que la minería de datos puede organizar conocimiento para el triaje, siempre que las métricas se acompañen de contexto, limitaciones y supervisión profesional.

12. Referencia

CDC. (s. f.). National Health and Nutrition Examination Survey [Conjunto de datos]. Kaggle.

<https://www.kaggle.com/datasets/cdc/national-health-and-nutrition-examination-survey>

Itachi9604. (s. f.). Disease symptom description dataset [Conjunto de datos]. Kaggle.

<https://www.kaggle.com/datasets/itachi9604/disease-symptom-description-dataset>

